

Informe Proyecto Final - Grupo#1

Semana: 9

Nombre de los estudiantes:

Allan Guillermo Bennett Torres – 62321289
Carlos Salvador Lopez Chinchilla - 62321402
Darleny Abigail Gómez Bulnes - 11951129

Sede de estudio:

Ceutec – San Pedro Sula – Sede Central

Docente:

Ing. Naomy Zoey Rios Reyes

Sección:

77 Ciencia de datos II

Fecha de entrega:

19 de Septiembre del 2026

Contenido

Introducción	3
Descripción del proyecto	4
Problema seleccionado	5
Pregunta de investigación	5
Justificación.....	5
Objetivos	6
Objetivo general.....	6
Objetivos específicos.....	6
Dataset	7
Fuente	7
Estructura	7
Diccionario de datos	8
Variable objetivo y privacidad	9
Proceso de Ciencia de Datos	9
ETL	10
Extracción	10
Transformación	10
Carga	11
Limpieza de datos	11
Análisis Exploratorio de Datos (EDA)	12
Balance de clases	13
Modelos utilizados	13
Regresión logística.....	13
Árbol de decisión.....	14
Random Forest	14
Resultados	14
Métricas	15
Decisiones que se pueden tomar	16
Valor agregado demostrado	17
Limitaciones	17
Futuras mejoras.....	18
Conclusiones	19
Bibliografías	20

Introducción

NewLinkWireless es un sistema CRM creado para apoyar la gestión de clientes de una empresa proveedora de servicios de internet. Dentro del sistema se almacena información relacionada con contratos, planes, facturación, pagos, soporte técnico e interacciones con los clientes.

A partir de estos datos, el proyecto busca agregar una parte de Ciencia de Datos que permita identificar posibles señales de cancelación antes de que el cliente abandone el servicio. Para esto se utilizará la información disponible en el CRM y se analizarán factores como la antigüedad, los tickets de soporte, los pagos atrasados, el tipo de servicio y el precio contratado.

En este avance se presenta el problema que se quiere resolver, los objetivos, la estructura del dataset, el proceso de preparación y análisis de los datos y los modelos que se consideran para realizar la predicción.

Descripción del proyecto

NewLinkWireless es un sistema CRM pensado para una empresa que brinda servicios de internet. Su función principal es reunir en un solo lugar la información relacionada con los clientes y los servicios que tienen contratados.

Dentro del sistema se pueden registrar clientes particulares y empresariales, administrar planes de internet, controlar contratos, instalaciones y equipos asignados, además de llevar el seguimiento de facturas, pagos y saldos pendientes. También permite registrar tickets de soporte técnico, interacciones con los clientes y el historial de suspensiones o cancelaciones.

La información esta almacenada en una base de datos SQL Server organizada mediante diferentes tablas relacionadas entre sí, para el desarrollo del proyecto se realizó la extracción y consolidación de los datos en un archivo CSV. Este archivo reúne la información necesaria sobre clientes, servicios, pagos, soporte y facturación, facilitando su limpieza, análisis y posterior visualización.

Además de servir para la gestión diaria de la empresa, toda esta información puede aprovecharse para realizar análisis sobre el comportamiento de los clientes. A partir de ahí surge la idea de incorporar Ciencia de Datos al CRM para tratar de identificar qué factores pueden estar relacionados con la cancelación de un servicio.

Problema seleccionado

Uno de los problemas que puede enfrentar una empresa proveedora de internet es la pérdida de clientes. En muchos casos, la empresa se da cuenta del problema cuando el cliente ya tomó la decisión de cancelar el servicio, por lo que queda poco margen para intentar retenerlo.

Sin embargo, antes de una cancelación pueden existir señales dentro de la información que ya maneja el CRM. Un cliente puede haber reportado varios problemas técnicos, acumular tickets sin resolver, presentar atrasos en sus pagos, tener suspensiones frecuentes o llevar poco tiempo utilizando el servicio.

Actualmente estos datos pueden revisarse de forma individual, pero no se utilizan en conjunto para estimar si un cliente presenta un mayor riesgo de cancelar.

Por esta razón, el proyecto se enfocará en analizar la información almacenada en NewLinkWireless para buscar patrones relacionados con la cancelación de servicios. La intención es utilizar esos datos para estimar qué clientes podrían tener un mayor riesgo y así contar con información que permita actuar antes de que la cancelación ocurra.

Pregunta de investigación

¿Se puede estimar el riesgo de cancelación de un cliente utilizando la información de sus servicios, pagos, facturación y solicitudes de soporte registradas en NewLinkWireless?

Justificación

Contar con una predicción de este tipo podría ayudar a la empresa a detectar con anticipación a clientes que presentan señales de posible abandono. A partir de esa información se podrían tomar acciones como revisar problemas técnicos pendientes, ofrecer un cambio de plan, mejorar la atención o dar un seguimiento más cercano.

El objetivo no es asegurar que un cliente va a cancelar, sino utilizar los datos disponibles para identificar casos que podrían necesitar mayor atención.

Objetivos

Objetivo general

Desarrollar un análisis de Ciencia de Datos que permita estimar el riesgo de cancelación de los clientes de NewLinkWireless utilizando la información almacenada en el CRM.

Objetivos específicos

Obtener la información necesaria sobre clientes, servicios contratados, planes, pagos, facturación y tickets de soporte.

Preparar y organizar los datos en un dataset que pueda utilizarse para analizar la cancelación de clientes.

Revisar y limpiar los registros para corregir datos incompletos, duplicados o inconsistentes.

Realizar un análisis exploratorio para identificar posibles relaciones entre las diferentes variables y la cancelación del servicio.

Analizar factores como antigüedad, precio, cantidad de tickets, tiempo de resolución, facturas vencidas y pagos atrasados.

Aplicar un modelo de clasificación que permita estimar el riesgo de cancelación.

Utilizar los resultados obtenidos como apoyo para identificar clientes que podrían requerir seguimiento.

Dataset

Fuente

Los datos utilizados en el proyecto provienen originalmente de la base de datos SQL Server de NewLinkWireless. Debido a que la información del CRM se encuentra distribuida en diferentes tablas relacionadas, los datos necesarios fueron extraídos y consolidados en un archivo CSV para facilitar su procesamiento y análisis.

El archivo CSV reúne información sobre clientes, servicios contratados, planes de internet, tickets de soporte, facturas, pagos, equipos e interacciones con los clientes. De esta manera, se dispone de un único dataset organizado para realizar las etapas de limpieza, exploración y preparación de los datos.

Para las pruebas del proyecto también se utilizarán registros simulados que mantengan una estructura y relación lógica con la información del CRM. Esto permitirá contar con una cantidad adecuada de datos para realizar el análisis y probar posteriormente los modelos de clasificación.

Estructura

El dataset se organizará de forma tabular y cada fila representará un servicio contratado por un cliente. Las columnas contendrán información relacionada con el servicio, la facturación, los pagos y el soporte técnico.

Entre las variables se encontrarán la antigüedad del servicio, el plan contratado, el precio, la velocidad de internet, la cantidad de tickets reportados, las facturas vencidas y los saldos pendientes.

Servicio	Antigüedad	Plan	Tickets	Fact. vencidas	Precio	Canceló
1	24	Fibra 100 Mbps	1	0	35.00	0
2	5	Inalámbrico 20 Mbps	6	3	25.00	1
3	18	Fibra 200 Mbps	2	1	50.00	0

Diccionario de datos

Variable	Tipo	Descripción
id_servicio	Entero	Identificador del servicio contratado
tipo_cliente	Categoría	Persona natural o empresa
tipo_servicio	Categoría	Fibra, cable, inalámbrico o dedicado
plan	Categoría	Nombre del plan contratado
velocidad_bajada_mbps	Entero	Velocidad de descarga
velocidad_subida_mbps	Entero	Velocidad de subida
precio_contratado	Decimal	Precio mensual acordado
antigüedad_meses	Entero	Meses desde la contratación
cantidad_equipos	Entero	Equipos asignados al servicio
cantidad_tickets	Entero	Total de tickets reportados
tickets_abiertos	Entero	Tickets todavía abiertos
tickets_criticos	Entero	Tickets de prioridad crítica
promedio_dias_resolucion	Decimal	Tiempo promedio de resolución
cantidad_facturas	Entero	Facturas emitidas
facturas_vencidas	Entero	Facturas vencidas
monto_facturado	Decimal	Total facturado
monto_pagado	Decimal	Pagos confirmados
saldo_pendiente	Decimal	Diferencia entre facturado y pagado
dias_atraso_promedio	Decimal	Promedio de retraso

cantidad_interacciones	Entero	Contactos registrados
estado_servicio	Catagórica	Estado actual del servicio
cancelo_servicio	Binaria	Objetivo: 0 no canceló; 1 canceló

Variable objetivo y privacidad

La variable principal utilizada para el modelo fue cancelo_servicio. Se asignó el valor 1 a los servicios identificados como cancelados y el valor 0 a los servicios no cancelados.

Esta variable forma parte del dataset simulado utilizado para el proyecto y funciona como la variable objetivo que los modelos de clasificación intentan predecir.

La información personal de los clientes, como nombres, teléfonos, direcciones, correos electrónicos y documentos de identificación, no fue utilizada para entrenar el modelo. Estos datos no eran necesarios para realizar la predicción y además se evitó incluir información personal que no aportaba valor al análisis.

Proceso de Ciencia de Datos

El proceso comenzará con la importación de la información consolidada en el archivo CSV, cuyos datos provienen originalmente de la base de datos SQL Server de NewLinkWireless. Posteriormente, se realizará la preparación y limpieza de los datos, corrigiendo valores faltantes, registros duplicados y posibles inconsistencias antes de desarrollar el análisis exploratorio.

Estas etapas permitirán obtener un dataset organizado, confiable y adecuado para utilizarlo posteriormente en la creación y evaluación de los modelos de clasificación.

ETL

Extracción

Los datos utilizados para el análisis estarán disponibles en un archivo CSV, el cual contiene información extraída y consolidada previamente desde la base de datos SQL Server de NewLinkWireless.

Este archivo reunirá los datos más importantes de clientes, servicios contratados, planes de internet, tickets de soporte, facturas, pagos y demás variables necesarias para el análisis.

El propósito será contar con un único dataset que permita identificar los factores que pueden estar relacionados con la permanencia o cancelación del servicio por parte de los clientes.

Transformación

Una vez cargado el archivo CSV, se realizarán diferentes verificaciones y ajustes para asegurar que los datos sean consistentes y estén preparados para el análisis exploratorio.

Entre las principales transformaciones se encuentran:

- Revisar los tipos de datos y las variables categóricas.
- Identificar valores nulos y registros duplicados.
- Verificar que los tickets abiertos y críticos no superen la cantidad total de tickets.
- Corregir las inconsistencias encontradas en las variables relacionadas con los tickets.
- Comprobar que los montos pagados no sean mayores que los montos facturados.
- Validar la relación entre el monto facturado, el monto pagado y el saldo pendiente.
- Verificar que las facturas vencidas no superen la cantidad total de facturas.
- Comprobar que no existan valores negativos en tickets, precios, antigüedad o días de atraso.
- Validar que la variable cancelo_servicio contenga únicamente los valores 0 y 1.
- Agrupar los datos para calcular promedios y porcentajes relacionados con la cancelación.

- Generar un nuevo archivo CSV con los datos limpios y preparados para el análisis exploratorio.

Carga

El archivo `dataset_cancelacion_newlinkwireless.csv` será cargado en Python mediante la librería Pandas. Posteriormente, se realizará la exploración inicial, validación y limpieza de los datos.

Una vez corregidas las inconsistencias identificadas, los datos se guardarán en un nuevo archivo llamado `dataset_cancelacion_newlinkwireless_limpio.csv`, el cual quedará preparado para realizar el análisis exploratorio.

Limpieza de datos

Antes de realizar el análisis exploratorio, se revisó la calidad del dataset para identificar valores nulos, registros duplicados e inconsistencias que pudieran afectar los resultados.

También se verificó que no existieran precios o valores de antigüedad negativos, saldos pendientes inconsistentes, montos pagados superiores a los facturados, facturas vencidas mayores que el total de facturas y valores incorrectos en los días de atraso. Además, se comprobó que la variable `cancelo_servicio` únicamente contuviera los valores 0 y 1.

Durante esta revisión se identificaron tres registros en los que la cantidad de tickets abiertos o críticos superaba la cantidad total de tickets. Estos valores fueron corregidos utilizando como límite máximo la cantidad total de tickets de cada servicio.

Finalmente, después de comprobar la consistencia de los datos, se generó el archivo `dataset_cancelacion_newlinkwireless_limpio.csv`, preparado para continuar con el análisis exploratorio.

Análisis Exploratorio de Datos (EDA)

El análisis exploratorio permitirá comprender el comportamiento de los datos e identificar los factores que pueden estar relacionados con la cancelación del servicio.

Primero se analizará la distribución de la variable `cancelo_servicio` para conocer la cantidad y el porcentaje de servicios cancelados y no cancelados. Posteriormente, se estudiará la cancelación en relación con las siguientes variables:

- Tipo de servicio contratado.
- Cantidad de tickets de soporte.
- Cantidad de facturas vencidas.
- Días promedio de atraso en los pagos.
- Antigüedad del servicio en meses.

Para facilitar la interpretación de los resultados, se utilizarán gráficos de barras y un diagrama de caja. También se calcularán porcentajes, promedios y medianas para comparar el comportamiento de los servicios cancelados con aquellos que permanecen activos.

El análisis buscará comprobar si una mayor cantidad de solicitudes de soporte, facturas vencidas y días de atraso, así como una menor antigüedad, están asociados con una mayor cancelación del servicio. Los resultados se interpretarán como asociaciones encontradas en el dataset y no necesariamente como relaciones de causa y efecto.

Balance de clases

También se revisará cuántos servicios cancelados existen en comparación con los que permanecen activos.

Esto es importante porque puede ocurrir que haya muchos más clientes activos que cancelados. Si existe una diferencia muy grande, será necesario tenerla en cuenta al momento de entrenar el modelo para evitar que aprenda principalmente de la clase con mayor cantidad de registros.

Modelos utilizados

El problema se trabajó como una clasificación binaria, debido a que la variable objetivo `cancelo_servicio` presenta dos posibles resultados: 0, cuando el servicio no fue cancelado, y 1, cuando el cliente canceló el servicio.

Para el proyecto se entrenaron y evaluaron tres algoritmos de clasificación:

Regresión logística

La Regresión Logística se utilizó como modelo inicial para estimar la probabilidad de cancelación de cada servicio. También sirvió como punto de referencia para comparar el rendimiento de los demás algoritmos.

Árbol de decisión

El Árbol de Decisión clasificó los registros mediante reglas basadas en las características de los clientes. Se estableció una profundidad máxima de cinco niveles para controlar la complejidad del modelo y reducir el riesgo de sobreajuste.

Random Forest

Random Forest combinó 200 árboles de decisión para generar predicciones más estables y reducir la dependencia de un único árbol. Este modelo obtuvo resultados competitivos, principalmente en Accuracy y Precision.

Los tres modelos se evaluaron utilizando las métricas Accuracy, Precision, Recall y F1-Score. Después de comparar los resultados, se seleccionó el Árbol de Decisión como modelo final porque presentó el mejor Recall y F1-Score, logrando identificar una mayor proporción de las cancelaciones reales. Esto resulta importante para que NewLinkWireless pueda detectar clientes en riesgo y tomar medidas preventivas.

Resultados

El dataset analizado contiene 1,000 servicios, de los cuales 201 fueron cancelados, lo que representa una tasa general de cancelación del 20.10 %. La antigüedad promedio general de los servicios fue de 29.60 meses.

El tipo de servicio con mayor porcentaje de cancelación fue el enlace dedicado, con un 23.73 %, seguido del servicio inalámbrico con 22.22 %, la fibra óptica con 20.91 % y el servicio de cable con 16.25 %.

Los servicios cancelados registraron un promedio de 4.72 tickets de soporte, mientras que los no cancelados presentaron solamente 2.17 tickets. Asimismo, los servicios cancelados tuvieron una antigüedad promedio de 19.85 meses, frente a los 32.05 meses registrados por los servicios que permanecieron activos.

En relación con los pagos, los servicios cancelados presentaron aproximadamente 13.63 días de atraso, mientras que los no cancelados registraron alrededor de 5.97 días. También se identificó un promedio de 4.21 facturas vencidas en los servicios cancelados, frente a 2.36 en los no cancelados.

Métricas

El Árbol de Decisión se evaluó con 200 registros del conjunto de prueba. El modelo clasificó correctamente 142 servicios que no fueron cancelados e identificó 23 cancelaciones reales. Sin embargo, generó 18 falsos positivos, correspondientes a servicios que fueron clasificados con cancelación, aunque permanecieron activos, y 17 falsos negativos, que representan cancelaciones reales que el modelo no logró detectar. Estos resultados muestran que el modelo puede utilizarse como una herramienta de apoyo para identificar clientes en riesgo, aunque sus predicciones no deben considerarse como una certeza absoluta.

El modelo identificó correctamente 23 de las 40 cancelaciones reales del conjunto de prueba. Aunque su capacidad de detección todavía puede mejorarse, permite reconocer patrones útiles para priorizar clientes que requieren seguimiento preventivo.

Al aplicar el modelo al dataset completo, los servicios se distribuyeron en los siguientes niveles:

- 655 servicios con riesgo bajo.
- 238 servicios con riesgo medio.
- 107 servicios con riesgo alto.

Estos resultados permiten que NewLinkWireless concentre sus acciones de retención principalmente en los 107 servicios clasificados con riesgo alto, revisando su historial de tickets, atrasos, facturas vencidas y antigüedad.

Los servicios cancelados presentaron un promedio de 13.63 días de atraso, mientras que los servicios no cancelados registraron un promedio de 5.97 días. Esta diferencia muestra que los atrasos en los pagos pueden estar relacionados con una mayor probabilidad de cancelación del servicio.

Decisiones que se pueden tomar

A partir de los resultados obtenidos, NewLinkWireless puede tomar las siguientes decisiones:

- Priorizar el seguimiento de los 107 servicios clasificados con riesgo alto.
- Aplicar campañas de retención a los clientes con riesgo medio y alto.
- Contactar a los clientes que presentan muchos tickets de soporte para conocer si sus problemas fueron solucionados.
- Dar mayor seguimiento a los clientes con facturas vencidas y atrasos frecuentes en sus pagos.
- Ofrecer convenios de pago o recordatorios antes de suspender el servicio.
- Fortalecer la atención durante los primeros meses, debido a que los clientes con menor antigüedad presentan más cancelaciones.
- Revisar la calidad de los servicios de enlace dedicado e inalámbrico, ya que muestran las tasas de cancelación más altas.

- Asignar atención técnica prioritaria cuando coincidan varios factores, como muchos tickets, atrasos y poca antigüedad.
- Utilizar el dashboard para monitorear periódicamente los cambios en el nivel de riesgo.
- Revisar cada caso antes de tomar una decisión, utilizando la predicción como apoyo y no como una certeza de cancelación.

Valor agregado demostrado

El proyecto aporta valor a NewLinkWireless al transformar los datos históricos del CRM en información útil para la toma de decisiones. Mediante el análisis exploratorio y el modelo de clasificación, es posible identificar servicios con mayor riesgo de cancelación antes de que el cliente abandone la empresa.

El sistema permite priorizar los 107 servicios clasificados con riesgo alto y reconocer factores relacionados con la cancelación, como una mayor cantidad de tickets, atrasos en los pagos, facturas vencidas y menor antigüedad. Esto facilita la aplicación de acciones preventivas, mejora el seguimiento de los clientes y permite utilizar los recursos de atención y soporte de una manera más eficiente.

Limitaciones

El proyecto presenta algunas limitaciones que deben considerarse al interpretar los resultados. El análisis se realizó con 1,000 registros simulados, por lo que los patrones encontrados podrían variar al utilizar información real de una empresa de internet. Además, el modelo fue desarrollado con las variables disponibles en el archivo CSV y podría no incluir otros factores importantes, como la satisfacción del cliente, la calidad de la conexión o las ofertas de la competencia.

El modelo tampoco garantiza que un cliente vaya a cancelar, ya que sus resultados representan estimaciones basadas en patrones históricos. Por esta razón, las predicciones deben utilizarse como apoyo para la toma de decisiones y complementarse con la revisión de cada caso. Asimismo, será necesario actualizar y volver a evaluar el modelo cuando se incorporen nuevos datos.

Futuras mejoras

Algunas mejoras futuras pueden ser:

- Crear un historial de predicciones para observar cómo cambia el nivel de riesgo de cada cliente.
- Incorporar información de llamadas, quejas e interacciones realizadas por el personal.
- Analizar las causas específicas de cancelación mediante encuestas de salida.
- Configurar alertas automáticas para los servicios clasificados con riesgo alto.
- Diseñar recomendaciones personalizadas según el problema de cada cliente.
- Evaluar el impacto de las campañas de retención aplicadas.
- Comparar el costo de retener un cliente con el costo de conseguir uno nuevo.
- Implementar validación cruzada para obtener una evaluación más confiable de los modelos.
- Ajustar el umbral de clasificación para detectar una mayor cantidad de cancelaciones.
- Incorporar técnicas como balanceo de clases para mejorar la detección de clientes que cancelan.
- Mostrar en Power BI las métricas del modelo y su evolución.
- Actualizar periódicamente el modelo con nuevos registros.
- Integrar las predicciones con el CRM para asignar automáticamente tareas de seguimiento.
- Proteger y anonimizar los datos personales utilizados durante el análisis.
- Crear perfiles de riesgo diferenciados según el tipo de servicio o plan contratado.

Conclusiones

- La información almacenada en el CRM de NewLinkWireless permitió construir un dataset orientado al análisis de la cancelación, integrando variables relacionadas con servicios, soporte técnico, facturación y pagos.
- La limpieza de los datos fue fundamental para asegurar resultados confiables. Durante este proceso se identificaron y corrigieron inconsistencias en tres registros donde los tickets abiertos o críticos superaban la cantidad total de tickets.
- El análisis exploratorio mostró que los servicios cancelados presentaron más tickets de soporte, facturas vencidas y días de atraso. También registraron una menor antigüedad en comparación con los servicios que permanecieron activos.
- Los tres modelos evaluados presentaron resultados diferentes. El Árbol de Decisión fue seleccionado porque obtuvo el mejor equilibrio para detectar cancelaciones reales, alcanzando un Recall de 57.50 % y un F1-Score de 56.79 %.
- El modelo permitió clasificar los servicios según su nivel de riesgo, identificando 107 casos de riesgo alto, 238 de riesgo medio y 655 de riesgo bajo. Esta clasificación facilita priorizar el seguimiento de los clientes que requieren mayor atención.
- Los dashboards desarrollados en Power BI facilitaron la interpretación de los resultados y permitieron visualizar los principales factores asociados con la cancelación, así como consultar la probabilidad y el nivel de riesgo de cada servicio.
- La solución demostró que la Ciencia de Datos puede complementar las funciones del CRM y apoyar decisiones preventivas. Sin embargo, las predicciones deben considerarse como estimaciones y no como una garantía de que el cliente cancelará.
- Debido a que el proyecto utilizó registros simulados, será necesario validar el modelo con datos reales y actualizarlo periódicamente antes de implementarlo como parte de la operación de NewLinkWireless.

Bibliografías

- Microsoft. (s. f.). *¿Qué es Power BI?* Microsoft Learn. Recuperado el 19 de septiembre de 2026, de <https://learn.microsoft.com/es-es/power-bi/fundamentals/power-bi-overview>
- pandas development team. (2026). *Package overview: pandas documentation*. https://pandas.pydata.org/docs/getting_started/overview.html
- Scikit-learn developers. (2026). *Decision trees*. Scikit-learn. <https://scikit-learn.org/stable/modules/tree.html>
- Scikit-learn developers. (2026). *Ensembles: Gradient boosting, random forests, bagging, voting and stacking*. Scikit-learn. <https://scikit-learn.org/stable/modules/ensemble.html>
- Scikit-learn developers. (2026). *Metrics and scoring: Quantifying the quality of predictions*. Scikit-learn. https://scikit-learn.org/stable/modules/model_evaluation.html